OFICINA PRÁTICA | ESTAGIÁRIOS

Estatística com Python

Investigando uma eleição fictícia

Objetivo: transformar dados tabulares em medidas estatísticas, gráficos e conclusões claras. Todas as contas e visualizações devem ser feitas em Python.

Nível: iniciante em análise de dados, com noções de variáveis e operações em Python. **Duração sugerida:** 120 minutos para as atividades principais; desafios opcionais para continuidade.

O conjunto de dados

O arquivo **eleicao_ficticia.csv** contém 24 seções, distribuídas em quatro bairros de um município inventado. Cada linha representa uma seção, em uma única eleição e um único turno. As candidaturas Ana, Bruno e Carla são fictícias. Os dados foram criados para esta aula; não representam resultados oficiais nem uma pesquisa eleitoral.

Coluna	Significado
secao	Identificador único da seção (não é uma medida).
bairro	Centro, Jardim, Lagoa ou Serra.
eleitores_aptos	Total de pessoas habilitadas a votar na seção.
abstencoes	Pessoas aptas que não compareceram.
votos_brancos / votos_nulos	Contagens de votos não válidos, separadas.
votos_ana / votos_bruno / votos_carla	Contagem de votos válidos por candidatura.

Formato: UTF-8, separador vírgula, cabeçalho na primeira linha e contagens inteiras. Não há dados pessoais. Não some a coluna secao como se ela fosse uma quantidade.

Entregue: um notebook .ipynb ou script .py executável, as tabelas solicitadas, três gráficos e um resumo de 5 a 8 linhas. Justifique cada resposta com números e identifique os denominadores dos percentuais.

Conheça a base

Reserve 25 minutos. Crie uma pasta e coloque o CSV e seu notebook ou script nela. Instale as bibliotecas no mesmo ambiente que executará o código.

```
python -m pip install pandas matplotlib
```

No notebook ou script, comece com:

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv("eleicao_ficticia.csv")
print(df.head())
```

1. Explore e classifique as variáveis

Exiba a dimensão da base, as primeiras cinco linhas e os tipos das colunas. Quantas seções e quantos bairros existem? Classifique bairro como variável qualitativa e as contagens como quantitativas discretas. Explique por que secao funciona como identificador.

Apoio: shape, head(), info(), nunique().

2. Verifique a qualidade dos dados

Conte valores ausentes por coluna e linhas duplicadas. Confira se secao é única, se todas as contagens são inteiras e não negativas e se abstencoes não supera eleitores_aptos. Mostre uma tabela apenas com registros que violem essas regras, mesmo que esteja vazia.

Apoio: isna().sum(), duplicated(), is_unique e filtros booleanos. Não remova registros sem justificar.

3. Reconstrua as quantidades da eleição

Crie comparecimento = eleitores_aptos - abstencoes e votos_validos = votos_ana + votos_bruno + votos_carla. Confira, em cada seção, se comparecimento = votos_validos + votos_brancos + votos_nulos. Calcule os totais de aptos, abstenções, comparecimento e votos válidos.

Apoio: Use operações entre colunas e sum(). Sua verificação deve produzir um resultado explícito para todas as linhas.

Pare e pense: por que não seria correto dividir o total de votos válidos pelo número de seções para obter a taxa de comparecimento?

Descreva e compare

Reserve 35 minutos. Crie as colunas derivadas sem alterar as contagens originais.

4. Calcule taxas por seção

Crie taxa_abstencao = 100 × abstencoes / eleitores_aptos e taxa_comparecimento = 100 × comparecimento / eleitores_aptos. Calcule também o percentual de votos brancos e nulos, somados, sobre o comparecimento. Liste as três seções com maior taxa de abstenção, com bairro, aptos e taxa.

Apoio: sort_values(), head(3). Verifique se os denominadores são maiores que zero; arredonde somente na apresentação.

5. Encontre o centro e a dispersão

Para eleitores_aptos e taxa_abstencao, apresente média, mediana, mínimo, máximo, amplitude, primeiro quartil, terceiro quartil e intervalo interquartil (Q3 - Q1). Calcule o desvio padrão populacional das taxas, usando ddof=0. Compare média e mediana em duas frases.

Apoio: mean(), median(), min(), max(), quantile([0.25, 0.75]) e std(ddof=0). Para quantis, use a interpolação linear padrão do pandas.

Convenção da aula: trate as 24 seções como a população completa deste município fictício. Por isso, use ddof=0 para o desvio padrão. O padrão de Series.std() é ddof=1, empregado no cálculo amostral. O desvio padrão de uma taxa expressa em % é apresentado em pontos percentuais.

6. Compare média simples e taxa global

Calcule (a) a média simples das 24 taxas de abstenção e (b) a taxa global: 100 × soma das abstenções / soma dos aptos. Informe a diferença em pontos percentuais. Qual medida responde à pergunta “qual fração dos eleitores do município se absteve”? Explique o papel do tamanho das seções.

Apoio: A taxa global equivale à média das taxas ponderada pelo número de eleitores aptos. Compare os valores antes de arredondar.

Cuidados de interpretação: um percentual depende de seu denominador. Uma diferença de 20% para 25% corresponde a 5 pontos percentuais; o aumento relativo é de 25%.

Conte a história dos dados

Reserve 40 minutos. Todas as tabelas devem ter rótulos claros e os gráficos devem indicar unidades.

7. Compare os bairros

Agrupe por bairro e some aptos, abstenções, comparecimento e votos válidos. A partir desses totais, recalcule a taxa de abstenção de cada bairro. Ordene os bairros pela taxa. Qual tem a maior taxa? Ele também tem a maior quantidade de abstenções? Explique a diferença entre contagem e taxa.

Apoio: groupby("bairro") com seleção explícita das colunas e sum(). Evite usar a média simples das taxas das seções como taxa do bairro.

8. Apure as candidaturas

Some os votos de Ana, Bruno e Carla no município. Calcule a participação de cada candidatura no total de votos válidos. Identifique a mais votada e a diferença para a segunda colocada em votos e em pontos percentuais. Depois, identifique a candidatura mais votada de cada bairro. Informe empates, se houver.

Apoio: Selecione apenas as três colunas de votos. Brancos, nulos e abstenções não entram no denominador dos votos válidos. Este exercício não exige regras legais de eleição.

9. Produza três gráficos

Crie: (a) barras com a taxa de abstenção por bairro; (b) histograma com seis classes para a taxa de abstenção das seções; (c) dispersão de eleitores_aptos no eixo x e taxa_abstencao no eixo y. Use títulos, rótulos e unidades; barras devem começar em zero. Salve os gráficos em PNG e escreva uma observação para cada um.

Apoio: plot.bar(), plt.hist(..., bins=6), plt.scatter() e plt.savefig(..., dpi=150, bbox_inches="tight"). No histograma, o eixo y representa o número de seções.

10. Escreva uma conclusão responsável

Em 5 a 8 linhas, relate a taxa global de abstenção, a candidatura mais votada e um contraste entre bairros. Cite pelo menos três números. Explique uma limitação da base e por que esses dados agregados não permitem afirmar quais pessoas votaram em cada candidatura nem explicar as causas da abstenção.

Apoio: Separe descrição de hipótese. Não generalize o município fictício para uma eleição real.

Desafios e documentação

A. Desafio opcional: associação

Calcule a correlação de Pearson entre eleitores_aptos e taxa_abstencao. Interprete o sinal e a intensidade à luz do gráfico de dispersão. Explique por que correlação não demonstra causalidade. Não interprete o resultado como comportamento individual de eleitores.

Apoio: df["eleitores_aptos"].corr(df["taxa_abstencao"]). Uma correlação próxima de zero não exclui toda relação não linear.

B. Desafio opcional: amostragem

Sorteie seis seções sem reposição com sample(n=6, random_state=42). Calcule a taxa de abstenção dessa amostra pela razão dos totais e compare com a taxa das 24 seções. Repita com sementes de 0 a 99 e faça um histograma das 100 estimativas. Explique a variabilidade e por que um único sorteio não garante representar bem todos os bairros.

Apoio: A unidade sorteada é a seção. Não trate as linhas como eleitores individuais; este exercício não fornece margem de erro para uma pesquisa eleitoral.

Documentação para consultar

Python: tutorial em português
https://docs.python.org/pt-br/3/tutorial/
Sintaxe, variáveis, listas e estruturas de controle.

pandas: tutoriais de introdução
https://pandas.pydata.org/docs/getting_started/intro_tutorials/index.html
Leitura de CSV, seleção, colunas derivadas, estatísticas e agrupamentos.

pandas: desvio padrão e ddof
https://pandas.pydata.org/docs/reference/api/pandas.Series.std.html
Diferença entre os divisores N e N - 1.

Matplotlib: tutorial de pyplot
https://matplotlib.org/stable/tutorials/pyplot.html
Criação e configuração dos gráficos.

Os links são clicáveis. A documentação de pandas e Matplotlib está em inglês; os exemplos de código ajudam a localizar cada operação. Vídeos não são necessários para concluir esta atividade.

Antes de entregar

Execute todo o código do início ao fim. Confira as identidades entre contagens, os denominadores e as unidades. Inclua o CSV junto ao código e use um caminho relativo. Cada exercício deve ter seu número, o código usado e uma resposta interpretada.

Sugestão para o instrutor: 10 min de abertura, 25 min de preparação, 35 min de estatística, 40 min de análise e 10 min de discussão. Avalie correção dos cálculos, clareza dos gráficos, interpretação e reprodutibilidade. Este caderno não inclui gabarito.